2026 CNN Inductive Bias 재조명 트렌드 리포트

기준일: 2026-04-20

조사 목적

이 문서는 `ViT 이후에도 CNN의 inductive bias가 왜 여전히 중요한가`를 연구 관점에서 정리한 리포트다.

여기서 말하는 핵심 inductive bias는 대체로 다음을 뜻한다.

- locality
- translation equivariance
- weight sharing
- multi-scale hierarchy
- spatially structured feature reuse

이 문서는 단순히 `CNN vs Transformer` 승패를 정리하려는 문서가 아니다.

- 어떤 문제에서 CNN bias가 아직도 유효한가
- Transformer가 실제로는 어떤 CNN priors를 다시 도입했는가
- foundation model 시대에도 도메인 특화 비전에서 CNN적 가정이 왜 다시 중요해지는가
- 앞으로 CNN 연구를 하려면 무엇을 “복원”하고 무엇을 “업데이트”해야 하는가

빠른 결론

1. `CNN bias는 사라진 것이 아니라, 많은 강한 비전 Transformer가 다시 부분적으로 도입한 설계 원리로 재등장했다.`
2. `대규모 사전학습과 강한 regularization이 있으면 ViT가 강하지만, 소규모 데이터·dense prediction·고해상도·실시간 제약에서는 CNN적 bias의 가치가 계속 드러난다.`
3. `ConvNeXt 이후의 흐름은 "CNN이 구식이다"가 아니라 "어떤 bias는 남기고 어떤 학습 관행은 Transformer 시대 방식으로 업데이트하자"에 가깝다.`
4. `앞으로의 좋은 CNN 연구는 순수 복고가 아니라, locality·hierarchy·equivariance를 현대적인 학습 스택과 결합하는 방향이어야 한다.`

---

1. 문제의식: 왜 지금 다시 CNN bias를 봐야 하나

ViT는 대규모 사전학습 환경에서 매우 강력한 결과를 보여 주었다. 원조 ViT 논문은 `충분히 큰 데이터셋으로 사전학습하면` pure transformer가 이미지 분류에서 매우 잘 동작함을 보였다.[1]

하지만 이 결과는 곧바로 `CNN bias가 필요 없다`는 뜻은 아니었다. 오히려 반대로, 비전 영역에서는 다음 조건들이 여전히 중요하다는 점이 반복적으로 드러났다.

- 데이터가 작을 때의 sample efficiency
- detection/segmentation 같은 dense prediction
- 고해상도 입력에서의 계산 비용
- 작은 객체와 다중 스케일 구조
- 배포 시 latency, memory locality, operator maturity

즉, ViT의 성공은 CNN bias의 완전한 폐기가 아니라 `bias와 scale의 교환관계`를 더 분명하게 드러낸 사건에 가깝다.

2. CNN이 원래 제공하던 것

CNN의 강점은 단순히 convolution 연산 그 자체가 아니다. 더 정확히는 아래 구조적 가정을 한 번에 제공했다는 데 있다.

2-1. locality

초기 층에서 가까운 공간 이웃을 우선적으로 결합한다. 이는 이미지의 국소적 상관구조와 잘 맞는다.

2-2. translation equivariance

같은 필터를 공간 전체에 공유하므로, 물체 위치가 변해도 같은 검출기가 작동한다. classification뿐 아니라 detection, tracking, segmentation에서 특히 중요하다.

2-3. hierarchical representation

깊어질수록 receptive field가 넓어지고 해상도는 줄며 의미 수준은 올라간다. 이 구조는 multi-scale vision task와 매우 잘 맞는다.

2-4. efficient sliding-window reuse

feature reuse와 operator 최적화가 잘 맞물린다. 실제 시스템에서는 FLOPs만이 아니라 memory traffic, kernel maturity, cache behavior가 중요하므로 이 이점은 아직도 작지 않다.

3. ViT가 가져온 변화는 무엇이었나

ViT는 patch token과 global self-attention으로 이미지를 처리하며, CNN이 강하게 고정하던 국소 priors를 훨씬 약하게 둔다.[1]

그 결과 얻는 장점은 명확하다.

- 더 유연한 장거리 상호작용
- architecture scaling의 단순성
- 대규모 pretraining과 결합했을 때의 높은 ceiling

하지만 비용도 있었다.

- 더 약한 지역 priors
- 작은 데이터에서의 학습 불안정성
- 고해상도에서 self-attention 비용 부담
- dense prediction으로 갈수록 추가 구조가 필요해짐

결국 비전에서 Transformer가 강해지는 과정은, NLP의 pure transformer를 그대로 가져오는 과정이 아니라 `비전용 priors를 다시 주입하는 과정`이었다.

4. 중요한 관찰 1: 강한 ViT들은 실제로 CNN적 priors를 다시 들여왔다

4-1. Swin Transformer는 hierarchy와 locality를 재도입했다

Swin Transformer는 shifted window를 통해 self-attention을 local window 안에서 계산하고, patch merging을 통해 계층적 representation을 만든다.[2]

중요한 함의는 이렇다.

- dense prediction에 강하려면 단일 해상도 token sequence만으로는 불리하다
- vision backbone으로 쓰려면 hierarchy가 다시 필요하다
- attention을 쓰더라도 locality 제약이 계산 효율과 일반화에 모두 도움이 된다

즉 Swin의 성공은 `CNN이 틀렸음`의 증거가 아니라, `Transformer도 결국 비전에서는 multi-scale local prior를 필요로 한다`는 증거에 가깝다.

4-2. CvT와 ConViT는 convolutional bias를 명시적으로 주입했다

CvT는 transformer 내부에 convolution을 도입해 shift/scale/distortion invariance를 강화하려 했다.[3] ConViT는 “soft convolutional inductive bias”라는 표현을 전면에 내세웠다.[4]

이 계열의 메시지는 명확하다.

- 비전 Transformer의 표현력이 높더라도, 초기 stage의 지역 bias는 여전히 유효하다
- hard bias와 soft bias 사이의 절충이 가능하다
- inductive bias는 성능 ceiling을 낮추는 족쇄가 아니라 sample efficiency를 사는 구조적 장치일 수 있다

4-3. early convolution stem은 “초반 bias”의 중요성을 다시 보여 줬다

`Early Convolutions Help Transformers See Better`는 patchify stem 앞단의 convolution이 optimization stability와 성능 모두에 유익할 수 있음을 보였다.[5]

연구적으로 보면 이건 매우 중요하다.

- bias는 전층에 균일하게 뿌릴 필요가 없을 수 있다
- 초반 representation formation 단계만 bias를 걸어도 충분할 수 있다
- “CNN vs ViT”보다 “어느 stage에서 어떤 bias가 필요한가”가 더 좋은 질문일 수 있다

5. 중요한 관찰 2: ConvNeXt는 CNN을 “현대적 대안”으로 되살렸다

ConvNeXt는 표준 ResNet을 Transformer 시대의 학습 관행과 설계 선택에 맞춰 modernize하면서, pure ConvNet만으로도 경쟁력 있는 결과를 얻을 수 있음을 보였다.[6]

이 논문이 던진 메시지는 매우 강하다.

- 일부 성능 격차는 attention의 본질적 우월성보다 training recipe와 macro design 차이에서 왔을 수 있다
- ConvNet은 더 이상 예전 ResNet 설정으로만 평가하면 안 된다
- hierarchical backbone, large kernel, inverted bottleneck, layer norm 등 현대화된 설계로 순수 CNN도 충분히 강하다

특히 ConvNeXt가 detection과 segmentation에서도 강한 결과를 보였다는 점은 중요하다.[6]

6. 중요한 관찰 3: data regime에 따라 inductive bias의 가치가 달라진다

6-1. 작은 데이터에서는 bias가 곧 regularization이다

`When Vision Transformers Outperform ResNets without Pre-training or Strong Data Augmentations`는 ViT가 적절한 regularization과 optimization을 갖추면 scratch에서도 강해질 수 있음을 보였지만, 동시에 그 과정 자체가 더 민감하고 recipe 의존적임을 드러냈다.[7]

즉, 해석은 이렇게 해야 한다.

- ViT가 작은 데이터에서 절대 안 된다는 것은 아니다
- 그러나 scratch regime에서 ViT는 CNN보다 더 많은 recipe engineering을 요구하는 경우가 많다
- CNN bias는 이런 설정에서 구조적 regularizer로 작동한다

DeiT 역시 외부 데이터 없이도 ViT를 강하게 훈련할 수 있음을 보였지만, 그 핵심은 distilled training과 강한 augmentation/regularization이었다.[8]

6-2. bias를 줄이면 데이터 요구량은 대체로 올라간다

ConViT는 hard inductive bias가 sample-efficient learning에 유리하지만 성능 ceiling을 제한할 수 있다고 정리했다.[4]

- 강한 bias: 적은 데이터, 빠른 수렴, 구조적 안정성
- 약한 bias: 더 큰 표현 유연성, 큰 데이터에서 높은 ceiling

앞으로의 핵심 질문은 `bias를 없앨 것인가`가 아니라 `bias의 강도를 어떻게 제어할 것인가`다.

7. 중요한 관찰 4: robustness와 shape-texture 문제는 아직 끝나지 않았다

Geirhos 등은 ImageNet-trained CNN이 shape보다 texture에 더 치우치는 경향을 보였고, shape bias를 높이면 정확도와 robustness가 함께 좋아질 수 있음을 보였다.[9]

한편 `Intriguing Properties of Vision Transformers`와 `Understanding The Robustness in Vision Transformers`는 ViT가 occlusion, corruption, shape 관련 평가에서 흥미로운 강점을 보인다고 분석했다.[10][11]

해석을 잘해야 한다.

- 일부 robustness 축에서는 ViT가 더 낫다
- 그러나 이것이 곧 모든 실제 배포 조건에서 ViT가 더 믿을 만하다는 뜻은 아니다
- 어떤 robustness가 architecture에서 오고, 어떤 robustness가 pretraining/data scale에서 오는지 분리해야 한다

8. 중요한 관찰 5: dense prediction은 CNN bias의 가치를 더 오래 남긴다

classification과 달리 detection/segmentation은 아래 요구가 강하다.

- 정확한 spatial localization
- multi-scale object handling
- 고해상도 feature map 유지
- local detail과 global context의 동시 활용

그래서 많은 strong detector/segmenter는 결국 다음 중 하나를 택했다.

- CNN backbone 유지
- hierarchical transformer 사용
- multi-scale feature pyramid 재도입

- local attention, deformable attention, hybrid stem 사용

`Benchmarking Detection Transfer Learning with Vision Transformers`도 detection transfer를 공정하게 평가하려면 backbone 호환성, feature pyramid, pretraining 방식, memory cost 등을 함께 봐야 함을 강조했다. [12]

9. 연구적으로 지금 정말 유용한 질문들

9-1. bias placement question

CNN bias를 어디에 넣는 것이 가장 효율적인가.

- stem만 convolution으로 둘 것인가
- early stage만 local prior를 둘 것인가
- decoder 쪽에만 multi-scale prior를 둘 것인가

9-2. bias strength question

hard equivariance가 필요한가, 아니면 soft locality bias면 충분한가.

- conv
- local attention
- relative position bias
- deformable sampling

을 동일 budget에서 비교할 가치가 크다.

9-3. regime-dependent comparison

아래 조건별 ranking이 달라지는지 보는 것이 중요하다.

- small data
- long-tail
- noisy labels
- OOD shift
- dense prediction
- edge deployment

9-4. representation geometry

CNN과 ViT의 feature geometry 차이가 실제 transfer와 robustness 차이로 이어지는지 분석할 필요가 있다.

10. 연구 설계 제안

이 주제를 실제 연구 프로젝트로 밀어 붙이려면 다음 비교축이 좋다.

- backbone family: ResNet-50, ConvNeXt-T, ViT-B/16, Swin-T, ConViT 또는 conv-stem ViT
- task family: ImageNet-1K classification, COCO detection, ADE20K segmentation, domain-specific dataset 1개
- regime split: full data, 10% labels, long-tail subset, synthetic corruption, natural shift

- measurement: clean accuracy, corruption robustness, calibration, convergence speed, GPU memory, latency, small-object AP 또는 boundary quality

핵심은 `단일 top-1`로 결론 내리지 않는 것이다.

11. 앞으로의 해석: CNN 연구는 어디로 가야 하나

지금 CNN 연구가 생산적이려면 아래 방향이 좋다.

- pure nostalgia가 아니라 `현대적 학습 스택과 결합된 CNN bias 연구`
- architecture 자체보다 `bias placement`와 `regime dependence`를 보는 연구
- classification만이 아니라 dense prediction, robustness, efficiency를 함께 보는 연구
- domain-specific vision에서 필요한 priors를 명시적으로 설계하는 연구

특히 의료영상, 산업검사, 위성, 로봇 비전, edge vision처럼 데이터가 작고 shift가 크며 latency가 중요한 분야에서는 CNN적 관점이 여전히 매우 강한 연구 출발점이 된다.

최종 정리

CNN이 끝났다는 표현은 과장에 가깝다.

- `순수하고 강한 CNN bias만으로 모든 문제를 해결하던 시대는 끝났다.`
- `하지만 비전 문제의 구조와 시스템 제약 때문에, locality·hierarchy·equivariance는 여전히 중요하다.`
- `실제로 많은 성공적인 Transformer는 이 priors를 다른 형태로 다시 도입했다.`

즉 2026년 기준으로 CNN 연구자에게 가장 좋은 태도는 방어가 아니라 재정식화다. 질문은 더 이상 `CNN이 아직 살아 있나`가 아니라 `어떤 bias가 어떤 조건에서 얼마나 필요한가`여야 한다.

참고문헌

[1] Dosovitskiy et al., *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale* (ICLR 2021)
OpenReview

[2] Liu et al., *Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows* (ICCV 2021)
CVF Open Access

[3] Wu et al., *CvT: Introducing Convolutions to Vision Transformers* (ICCV 2021)
CVF Open Access

[4] D'Ascoli et al., *ConViT: Improving Vision Transformers with Soft Convolutional Inductive Biases* (ICML 2021)
PMLR

[5] Xiao et al., *Early Convolutions Help Transformers See Better* (CoRR 2021)
OpenReview PDF

[6] Liu et al., *A ConvNet for the 2020s* (CVPR 2022)
CVF Open Access

[7] Chen et al., *When Vision Transformers Outperform ResNets without Pre-training or Strong Data Augmentations* (ICLR 2022)
OpenReview PDF

[8] Touvron et al., *Training data-efficient image transformers & distillation through attention* (ICML 2021)
PMLR

[9] Geirhos et al., *ImageNet-trained CNNs are biased towards texture; increasing shape bias improves accuracy and robustness* (ICLR 2019)
OpenReview

[10] Naseer et al., *Intriguing Properties of Vision Transformers* (NeurIPS 2021)
OpenReview PDF

[11] Zhou et al., *Understanding The Robustness in Vision Transformers* (ICML 2022)
PMLR

[12] Li et al., *Benchmarking Detection Transfer Learning with Vision Transformers* (CoRR 2021)
arXiv