2026 Data-Centric Vision and Synthetic Data 트렌드 리포트

기준일: 2026-04-22

조사 목적

이 문서는 모델 아키텍처 자체보다 데이터 파이프라인이 성능과 배포성을 더 크게 좌우하는 시점에서, 컴퓨터비전 연구와 실무가 데이터 중심으로 어떻게 이동하고 있는지를 정리한 리포트다.

다루는 범위는 다음과 같다.

- data curation, filtering, reweighting
- noisy label, long-tail, class imbalance
- synthetic data와 simulation data
- synthetic pretraining, dataset distillation, subset selection
- 산업검사·의료영상·희귀 이벤트 탐지에서의 실전 함의

핵심 질문은 아래다.

- 2026년 기준으로 비전 성능 향상의 핵심 병목은 모델보다 데이터에 더 가까운가
- synthetic data는 어디까지 실제 데이터를 대체할 수 있고, 어디서부터 한계가 분명해지는가
- CNN 기반 CV 엔지니어가 실전에 가져가야 할 data-centric 사고방식은 무엇인가

빠른 결론

1. 지금 비전 성능 차이의 상당 부분은 아키텍처보다 데이터 구성, 품질 관리, 학습 샘플링 전략에서 난다.
2. synthetic data는 특히 희귀 클래스, 위험 상황, 라벨 비용이 큰 태스크, 산업용 결함 검출에서 강력하지만, 자동으로 natural robustness를 주지는 않는다.
3. 좋은 synthetic pipeline은 “이미지 생성”만이 아니라 scene design, label fidelity, coverage control, domain gap 측정, real-data mixing까지 포함한다.
4. dataset distillation과 subset selection은 단순 압축이 아니라, 앞으로 low-cost retraining과 edge deployment를 위한 핵심 기술 축이 될 가능성이 크다.
5. 실전에서는 synthetic-only보다 real + synthetic + filtering + uncertainty-aware evaluation 조합이 훨씬 현실적이다.

---

1. 왜 지금 data-centric vision을 따로 봐야 하나

한동안 비전 연구의 중심은 backbone과 head architecture였다.

- ResNet에서 EfficientNet으로
- EfficientNet에서 ViT/Swin으로
- detector는 Faster R-CNN에서 DETR 계열로
- segmentation은 U-Net 계열에서 foundation segmentation으로

하지만 실제 현장에서는 아래 문제가 더 자주 성능을 결정한다.

- 라벨 오류가 얼마나 많은가
- rare case가 학습셋에 들어 있는가
- 클래스 비율이 배포 환경과 비슷한가
- 테스트 환경의 조명, 배경, 장비, 각도, 속도가 훈련셋에 반영되어 있는가
- hard negative가 충분한가

즉 실전의 병목은 종종 모델 표현력 부족이 아니라 학습 데이터가 문제 구조를 제대로 덮지 못하는 것이다.

이 흐름은 특히 아래 영역에서 강하다.

- 산업검사
- 의료영상
- 원격탐사
- 자율주행/로보틱스
- 보안/감시

이 분야들은 공통적으로 라벨 비싸고, 실패 비용 크고, 희귀 사례 중요하고, 분포 이동이 잦다는 특징을 갖는다.

2. data-centric vision은 무엇을 뜻하나

data-centric vision은 단순히 “데이터 더 많이 모으자”가 아니다.
더 정확한 의미는 모델을 고정하거나 약하게 바꾸더라도 데이터 파이프라인을 설계해 성능을 끌어올리는 접근이다.

핵심 구성은 아래처럼 보는 편이 실용적이다.

2-1. 수집과 커버리지 설계

- 어떤 조건을 반드시 포함할지 정의
- rare case와 failure case를 의도적으로 모으기
- 클래스별 수량보다 nuisance factor coverage를 관리

2-2. 정제와 품질 관리

- 오라클 재검수
- noisy label 탐지
- near-duplicate 제거
- 잘못된 bounding box / mask 수정

2-3. 학습 샘플링과 재가중치

- long-tail 보정
- hard example mining
- domain-balanced sampling
- curriculum 또는 confidence-aware weighting

2-4. synthetic augmentation과 synthetic generation

- classical augmentation
- simulator 기반 생성
- generative model 기반 생성

- rare case 보강용 scenario synthesis

2-5. 데이터 축소와 압축

- coreset selection
- dataset distillation
- subset selection

결국 data-centric vision은 모델 바깥의 전처리 작업이 아니라, `모델과 같은 급의 연구 대상`이 되고 있다.

3. synthetic data를 한 덩어리로 보면 자주 틀린다

synthetic data는 종류가 매우 다르다. 이걸 구분하지 않으면 기대치가 과장되기 쉽다.

3-1. simulator / rendering 기반 synthetic data

이 방식은 장면과 라벨을 정밀하게 제어할 수 있다.

- 카메라 위치
- 광원
- 재질
- 객체 배치
- 배경 분포
- 정답 마스크 / depth / pose

이 계열의 장점은 `label fidelity`와 `coverage control`이다.
예를 들어 `BEHAVIOR Vision Suite`는 시뮬레이션 기반으로 시각 데이터 생성과 체계적 평가를 연결하려는 방향을 보여 준다.[1]

이런 방식은 특히 아래에 강하다.

- 로봇 조작
- embodied perception
- multi-view geometry
- 산업 부품 검사

3-2. generative model 기반 synthetic data

확산모델이나 생성모델을 이용한 synthetic data는 실제 이미지를 대량으로 대체하거나 보강하려는 방향이다.

장점은 분명하다.

- 클래스별 생산 속도가 빠르다
- 비용이 낮다
- 희귀 상황을 빠르게 늘릴 수 있다
- text prompt나 scene prompt로 데이터 다양성을 통제할 수 있다

하지만 약점도 분명하다.

- 텍스처와 배경 shortcut이 비현실적으로 고정될 수 있다
- 물리적 일관성이 깨질 수 있다
- class semantics는 맞지만 localization label은 부정확할 수 있다

- 생성 편향이 robustness를 악화시킬 수 있다

`SynCLR`은 synthetic image만으로도 경쟁력 있는 representation learning이 가능함을 보여 준 대표 사례다.[2]
다만 이 결과를 곧바로 `실전 downstream도 synthetic-only로 충분하다`로 해석하면 과하다.

3-3. task-specific synthetic pretraining

일부 영역에서는 synthetic data가 "최종 훈련셋"보다 `pretraining source`로 특히 강하다.

`Label-Free Synthetic Pretraining of Object Detectors`는 detection에서 synthetic data를 사전학습 재료로 활용하는 방향을 보여 줬다.[3]

이 접근이 실전적인 이유는 다음과 같다.

- synthetic 쪽에서는 값싼 coverage 확보
- real 쪽에서는 소량 고품질 fine-tuning
- 둘을 섞어 real annotation 비용을 줄임

즉 synthetic data의 가장 현실적인 위치는 종종 `완전 대체재`가 아니라 `representation warm-start`다.

4. synthetic data가 실제로 강한 곳

synthetic data는 모든 영역에서 같은 힘을 내지 않는다.
특히 아래 조건에서 효과가 크다.

4-1. rare event와 safety-critical case

실제 데이터로는 거의 못 모으는 케이스다.

- 사고 직전 장면
- 특정 결함 패턴
- 극단적 기상 조건
- 드문 질환 소견

이런 조건에서는 "평균적인 자연 이미지 추가 수집"보다 `의도적으로 만든 synthetic rare case`가 더 큰 가치가 있다.

4-2. 산업검사와 결함 탐지

산업검사는 data-centric 접근과 synthetic data가 특히 잘 맞는다.

- 정상 데이터는 많다
- 결함 데이터는 적다
- 라벨이 비싸다
- 카메라, 조명, 재질이 통제 가능하다

`Synthetic Data for Defect Segmentation on Complex Metal Surfaces`는 실제 산업 부품 검사에서 synthetic pretraining이 유효함을 보여 준다.[4]

이 영역에서 중요한 것은 단순 다양성보다 아래다.

- 반사광 모델링

- 재질 일관성
- 결함 morphology realism
- multi-view coverage

4-3. representation learning

synthetic data는 최종 supervised training보다 representation learning에서 더 넓게 먹히는 경우가 있다.

- pretraining
- contrastive learning
- masked modeling
- synthetic caption 기반 alignment

이 경우 핵심은 개별 픽셀 realism보다 `semantic coverage와 transformation diversity`다.

5. 그러나 synthetic data는 robustness의 공짜 답이 아니다

가장 흔한 오해는 아래다.

- synthetic 데이터가 많으면 distribution shift도 해결된다
- synthetic pretraining이 강하면 calibration도 좋아진다
- 렌더링 realism만 높이면 실전 배포가 해결된다

이 셋은 대체로 성립하지 않는다.

`Is Synthetic Data all We Need? Benchmarking the Robustness of Models Trained with Synthetic Images`는 synthetic-only 학습의 robustness를 별도로 따져야 한다는 점을 보여 준다.[5]

핵심 함의는 다음과 같다.

- clean accuracy와 robust accuracy는 분리해서 봐야 한다
- synthetic coverage가 넓어 보여도 nuisance factor 분포가 실제와 다를 수 있다
- 생성 파이프라인의 bias가 그대로 학습 bias가 된다

특히 CNN 기반 비전 시스템에서는 아래 failure mode를 자주 본다.

- 배경과 클래스가 잘못 결합됨
- 조명/반사 패턴이 과도하게 규칙적임
- sensor noise가 실제와 다름
- object boundary나 defect morphology가 비현실적임

즉 synthetic data는 "데이터를 싸게 만드는 기술"이 아니라 `분포를 설계하는 기술`로 봐야 한다.

6. synthetic data보다 더 자주 문제를 일으키는 것: noisy label과 long-tail

실전 CV 엔지니어링에서 synthetic data보다 먼저 처리해야 할 때가 많은 문제가 두 가지다.

- noisy label
- long-tailed distribution

`Learning to Learn From Noisy Labeled Data`는 noisy label 학습이 별도 연구 축이어야 함을 보여 준 고전적 기준선이다.[6]

최근에는 이 문제가 long-tail과 결합된 형태로 더 자주 나타난다.
`Label-Noise Learning with Intrinsically Long-Tailed Data`는 label noise와 tail imbalance가 동시에 있을 때 표준 기법이 쉽게 무너질 수 있음을 보여 준다.[7]

실전적으로 중요한 이유는 간단하다.

- 희귀 클래스일수록 라벨이 더 불안정하다
- pseudo-label을 쓰면 tail이 더 악화되기 쉽다
- synthetic 샘플을 추가해도 real label noise를 덮지는 못한다

즉 data-centric vision의 우선순위는 종종 아래 순서가 맞다.

1. 라벨 품질 정리
2. 클래스/도메인 불균형 보정
3. hard case 추가 수집
4. 그다음 synthetic data

7. dataset distillation과 subset selection은 왜 중요해졌나

dataset distillation은 큰 데이터를 작은 대표 synthetic set으로 압축하려는 분야다.
처음엔 장난감 문제처럼 보였지만, 지금은 의미가 훨씬 커졌다.

- 반복 학습 비용 절감
- edge용 재학습 파이프라인 단순화
- 데이터 저장 비용 감소
- 빠른 ablation과 hyperparameter search

`Scaling Up Dataset Distillation to ImageNet-1K with Constant Memory`는 이 주제를 대규모 이미지 셋으로 끌어올린 중요한 작업이다.[8]
`SelMatch`는 selection과 distillation을 결합하는 방향이 더 강할 수 있음을 보여 준다.[9]

이 흐름의 함의는 명확하다.

- 앞으로 "어떤 데이터를 학습에 넣을지"가 아키텍처 선택만큼 중요해진다
- 모든 데이터를 매번 다 쓰는 훈련 파이프라인은 비효율적일 수 있다
- 현장 배포용 모델 업데이트는 full retraining보다 data-compressed retraining 쪽으로 갈 수 있다

8. CNN 기반 CV 엔지니어 입장에서의 실전 프레임

CNN 기반 영상처리 엔지니어라면 synthetic data를 너무 거창하게 볼 필요는 없다.
아래처럼 보는 편이 현실적이다.

8-1. 먼저 실제 데이터의 실패 분포를 계측한다

- 어떤 조명에서 깨지는가
- 어떤 배경에서 오탐이 나는가
- 어떤 결함 크기에서 미탐이 늘어나는가
- 어느 장비/센서에서 붕괴하는가

8-2. synthetic data는 그 실패 분포를 메우는 용도로 쓴다

- rare case 확장
- hard negative 생성
- annotation 비용이 큰 segmentation mask 보강
- extreme condition 보강

8-3. real과 synthetic을 섞되 분리 평가한다

- real-only baseline
- real + synthetic
- synthetic pretrain + real finetune

이 세 조건을 분리해서 봐야 무엇이 실제로 도움이 되는지 알 수 있다.

8-4. 최종 평가는 항상 real deployment proxy에서 한다

- natural shift
- calibration
- false positive cost
- latency under real pipeline

synthetic validation이 좋아도 real deployment proxy가 나쁘면 그 실험은 실패다.

9. 앞으로 중요한 연구 질문

지금 시점에서 특히 값어치가 큰 질문은 아래다.

1. `synthetic diversity`와 `realistic nuisance fidelity` 중 무엇이 더 중요한가
2. synthetic pretraining 이득은 어떤 도메인에서 longest-lasting transfer로 남는가
3. dataset distillation은 분류를 넘어 detection/segmentation까지 얼마나 실용화될 수 있는가
4. noisy label 정제와 synthetic augmentation 중 어느 쪽이 투자 대비 이득이 큰가
5. synthetic data가 calibration과 uncertainty estimation에 주는 영향은 무엇인가

10. 읽기 우선순위

이 주제를 빠르게 잡으려면 아래 순서가 좋다.

1. noisy label / long-tail 학습
   데이터 품질 문제가 얼마나 크고 복합적인지 이해

2. synthetic pretraining과 synthetic-only learning
   synthetic data의 현실적 쓰임새 파악

3. 산업/도메인 특화 synthetic 사례
   어디서 진짜 잘 먹히는지 확인

4. dataset distillation / subset selection
   앞으로의 효율화 방향 이해

5. robustness evaluation
   synthetic 성능을 어디까지 믿어야 하는지 점검

최종 정리

2026년의 data-centric vision은 `모델보다 데이터를 보자`는 구호 수준을 이미 넘었다.

더 정확한 표현은 아래에 가깝다.

- 모델은 점점 범용화된다
- 성능 차이는 점점 데이터 파이프라인에서 벌어진다
- synthetic data는 매우 강력하지만, 분포 설계를 잘못하면 오히려 착시를 준다
- 실제 경쟁력은 `real data quality + synthetic coverage + honest evaluation` 조합에서 나온다

즉 좋은 비전 시스템은 더 이상 `강한 backbone 하나`가 아니라, `좋은 데이터 생성·정제·선택·평가 루프`를 가진 시스템이다.

참고문헌

[1] Ge et al., *BEHAVIOR Vision Suite: Customizable Dataset Generation via Simulation* (CVPR 2024)
CVF Open Access

[2] Tian et al., *Learning Vision from Models Rivals Learning Vision from Data* (CVPR 2024)
CVF Open Access

[3] Law and Deng, *Label-Free Synthetic Pretraining of Object Detectors* (WACV 2024)
CVF Open Access

[4] Fulir et al., *Synthetic Data for Defect Segmentation on Complex Metal Surfaces* (CVPR Workshops 2023)
CVF Open Access

[5] Singh et al., *Is Synthetic Data all We Need? Benchmarking the Robustness of Models Trained with Synthetic Images* (CVPR Workshops 2024)
CVF Open Access PDF

[6] Li et al., *Learning to Learn From Noisy Labeled Data* (CVPR 2019)
CVF Open Access

[7] Lu et al., *Label-Noise Learning with Intrinsically Long-Tailed Data* (ICCV 2023)
CVF Open Access

[8] Cui et al., *Scaling Up Dataset Distillation to ImageNet-1K with Constant Memory* (ICML 2023)
PMLR

[9] Lee and Chung, *SelMatch: Effectively Scaling Up Dataset Distillation via Selection-Based Initialization and Partial Updates by Trajectory Matching* (ICML 2024)
PMLR