2026 Efficient Vision Backbone 연구노트

기준일: 2026-04-21

목적

이 문서는 지금 비전 백본(backbone)을 어떻게 봐야 하는가를 연구 관점에서 정리한 노트다.

여기서 말하는 백본은 단순 분류 모델을 뜻하지 않는다.
오히려 다음 태스크에서 공통 표현 추출기로 쓰이는 구조를 뜻한다.

- image classification
- object detection
- segmentation
- tracking / video understanding
- multimodal vision encoder
- on-device / edge deployment

핵심 질문은 아래다.

- 2026년 기준으로 강한 비전 백본 계보는 어떻게 나뉘는가
- CNN, ViT, hierarchical transformer, deformable conv, SSM 계열을 어떤 기준으로 비교해야 하는가
- "좋은 백본"은 정확도만 높은 모델인가, 아니면 데이터 조건과 시스템 제약에 따라 달라지는가

빠른 결론

1. 단일 백본이 모든 조건에서 최선인 시대는 아니다.
2. 분류 중심의 최고 성능과 dense task/배포 효율 중심의 최고 성능은 종종 다르다.
3. 좋은 백본을 고르려면 accuracy보다 먼저 inductive bias, scaling behavior, resolution cost, downstream compatibility를 봐야 한다.
4. ConvNeXt 계열은 CNN을 현대화한 강한 기준선이고, Swin 계열은 vision transformer를 dense task 친화적으로 만든 기준선이며, InternImage는 대규모 비전용 convolution의 재부상을 보여 준다.
5. 최근 SSM/Mamba 계열은 long-range modeling과 linear-time scaling의 가능성을 보여 주지만, 아직은 "모든 곳에 바로 대체 가능한 지배적 백본"이라기보다 탐색 가치가 큰 신흥 축으로 보는 편이 정확하다.

---

1. 좋은 백본을 평가할 때 무엇을 봐야 하나

비전 백본을 비교할 때 흔히 top-1 accuracy만 본다.
하지만 실제 연구와 시스템 설계에서는 그 기준이 너무 약하다.

적어도 아래 6가지는 함께 봐야 한다.

1-1. inductive bias

- locality가 강한가

- translation equivariance를 얼마나 유지하는가
- multi-scale hierarchy를 구조적으로 제공하는가
- 전역 문맥을 early stage부터 잘 섞는가

1-2. scaling behavior

- 데이터가 늘 때 얼마나 잘 올라가는가
- 해상도가 커질 때 계산량이 어떻게 증가하는가
- 모델 크기를 키웠을 때 학습 안정성이 유지되는가

1-3. downstream compatibility

- detection/segmentation neck과 잘 붙는가
- feature pyramid를 만들기 쉬운가
- dense prediction에서 고해상도 특성을 잘 보존하는가

1-4. optimization recipe sensitivity

- 강한 augmentation과 regularization이 꼭 필요한가
- scratch 학습에 민감한가
- pretraining 의존도가 큰가

1-5. deployment efficiency

- FLOPs 대비 실제 latency가 좋은가
- operator가 하드웨어 친화적인가
- memory footprint가 작은가

1-6. transfer robustness

- small-data fine-tuning에 안정적인가
- natural distribution shift에서 성능이 덜 무너지는가
- calibration이나 uncertainty behavior가 덜 나쁜가

이 프레임으로 봐야 백본 논쟁이 “유행 모델 소개”에서 “연구 설계”로 넘어간다.

2. 큰 계보: 비전 백본은 대략 다섯 축으로 정리된다

2026년 시점의 대표 계보는 아래처럼 정리하는 편이 가장 실용적이다.

1. `고전 CNN 효율 계보`
2. `현대화된 ConvNet 계보`
3. `pure / hierarchical transformer 계보`
4. `대규모 비전 특화 convolution 계보`
5. `SSM / hybrid long-range modeling 계보`

이 다섯 축을 순서대로 보는 것이 좋다.

---

3. 고전 CNN 효율 계보: MobileNetV2와 EfficientNet이 남긴 것

3-1. MobileNetV2의 핵심

MobileNetV2는 inverted residual과 linear bottleneck으로 mobile setting에서 표현력과 비용 사이 균형을 잡았다.[1]

왜 아직도 중요한가.

- depthwise separable convolution은 여전히 모바일 연산 최적화의 기준점이다
- 채널 확장 후 projection하는 inverted residual은 경량 네트워크 설계의 기본 문법이 되었다
- on-device vision에서 operator maturity가 중요하다는 사실을 일찍 보여 줬다

즉 MobileNetV2는 "옛날 모바일 모델"이 아니라, 지금도 효율성은 연산식만이 아니라 하드웨어 친화적 분해 전략에서 나온다는 교훈을 준다.

3-2. EfficientNet의 핵심

EfficientNet은 depth, width, resolution을 compound scaling으로 함께 조정해야 효율적이라는 점을 보여 줬다.[2]

연구적으로 중요한 포인트는 아래다.

- 스케일링은 한 축만 키우는 문제가 아니다
- 좋은 백본은 base architecture뿐 아니라 scaling law가 좋아야 한다
- downstream에 붙을 모델이라면 backbone 자체 성능보다 "어떻게 커지는가"가 더 중요할 수 있다

오늘 기준으로 EfficientNet 계열이 SOTA의 중심은 아니지만, 효율 연구의 사고방식에는 여전히 남아 있다.

4. 현대화된 ConvNet 계보: ConvNeXt와 ConvNeXt V2

4-1. ConvNeXt가 바꾼 것

ConvNeXt는 ResNet을 Transformer 시대의 학습 관행에 맞게 업데이트하면 pure ConvNet도 매우 강력한 backbone이 될 수 있음을 보여 줬다.[3]

중요한 메시지는 이렇다.

- CNN의 한계로 보였던 일부는 아키텍처 본질보다 recipe 문제였을 수 있다
- large kernel, patchify stem, inverted bottleneck, LayerNorm 같은 요소는 CNN에도 효과적이다
- dense prediction에서는 여전히 계층형 ConvNet이 강력한 기본 선택지다

즉 ConvNeXt는 CNN이 끝나지 않았다는 주장보다, 현대적 기준선으로 재평가해야 한다는 주장에 가깝다.

4-2. ConvNeXt V2의 의미

ConvNeXt V2는 masked autoencoder류 자기지도 학습과 ConvNet co-design을 더 밀어붙인 작업이다.[4]

이 논문이 중요한 이유는 다음과 같다.

- self-supervised pretraining은 Transformer만의 영역이 아님을 보여 줬다
- ConvNet도 representation learning regime을 바꾸면 추가로 좋아질 수 있음을 보여 줬다
- backbone 비교는 supervised-only 세팅으로 끝내면 안 된다는 점을 강조한다

연구자 관점에서는 이 지점이 중요하다.

- ConvNet이 약해서 진 것이 아니라 pretraining culture에서 뒤처졌을 수 있다
- 따라서 “Conv vs ViT” 비교는 pretraining protocol까지 맞춰야 공정하다

5. Transformer 백본 계보: ViT, DeiT, Swin

5-1. ViT의 의미

ViT는 patch token과 self-attention만으로 large-scale pretraining 하에서 매우 강한 이미지 인식을 달성했다.[5]

이 모델이 남긴 가장 큰 교훈은 다음이다.

- 충분한 데이터와 compute가 있으면 약한 inductive bias도 높은 ceiling을 가질 수 있다
- 비전 백본도 NLP처럼 token sequence view로 다룰 수 있다
- scale이 model design의 일부가 되었다

하지만 곧바로 현실 문제가 드러났다.

- small-data에서 불안정
- dense task와의 결합 비용
- 고해상도 attention 비용

5-2. DeiT의 의미

DeiT는 외부 거대 데이터 없이도 data-efficient training recipe로 ViT를 강하게 훈련할 수 있음을 보였다.[6]

연구적으로 보면 중요한 메시지는 이렇다.

- 약한 구조적 bias의 부족분을 학습 절차가 메워 줄 수 있다
- knowledge distillation과 augmentation은 backbone 비교에서 매우 큰 교란변수다
- “어떤 백본이 더 낫나”를 말할 때 recipe를 빼면 결론이 흔들린다

5-3. Swin의 의미

Swin Transformer는 shifted window와 patch merging으로 hierarchical representation을 복원했다.[7]

왜 중요한가.

- dense vision에서는 hierarchy가 구조적으로 중요하다는 점을 다시 확인시켰다
- local attention은 효율성 타협이 아니라 비전용 inductive bias로 볼 수 있다
- transformer backbone도 vision downstream task에 맞추려면 결국 multi-scale을 다시 도입하게 된다는 점을 보여 줬다

즉 Swin은 “pure transformer의 승리”라기보다 “vision transformer의 현실적 수렴점”에 가깝다.

6. 대규모 비전 특화 convolution: InternImage

InternImage는 deformable convolution을 대규모 비전 foundation model 관점으로 확장하며, large-scale vision backbone으로서의 ConvNet 잠재력을 다시 부각시켰다.[8]

이 모델이 중요한 이유는 아래다.

- convolution도 단순 local fixed kernel에 머무르지 않는다

- deformable sampling은 locality와 adaptivity를 함께 제공한다
- large model regime에서도 비전 특화 spatial inductive bias가 여전히 강력할 수 있다

특히 dense prediction 관점에서 deformable mechanism은 매우 매력적이다.

- 객체 크기와 형태 변화에 더 유연하다
- feature sampling을 태스크 구조에 맞게 조정할 수 있다
- detection/segmentation과 자연스럽게 잘 맞는다

즉 InternImage는 `대규모 백본 = transformer`라는 단순 도식을 깨는 대표 사례다.

7. SSM / Mamba 계열: 새로운 백본 축인가, 아직은 탐색 축인가

7-1. Vision Mamba 계열의 약속

Visual state space model 계열은 self-attention의 quadratic cost를 피하면서 장거리 의존성을 효율적으로 다룰 수 있다는 기대를 받는다.
Vision Mamba는 bidirectional state space model로 효율적 시각 표현 학습 가능성을 제시했다.[9]

7-2. VMamba의 의미

VMamba는 2D selective scan을 도입해 vision backbone으로서 SSM을 좀 더 직접적으로 제시했다.[10]

이 계열이 흥미로운 이유는 다음과 같다.

- attention 없는 long-range mixing 대안이 생긴다
- 해상도 증가에 따른 scaling이 더 유리할 가능성이 있다
- token mixer 설계의 새로운 축을 연다

하지만 아직 조심해야 한다.

- operator maturity가 conv만큼 높지 않다
- 실제 latency가 이론 FLOPs 개선과 일치하지 않을 수 있다
- dense task와의 결합에서 검증이 더 필요하다

7-3. MambaVision의 의미

MambaVision은 hybrid Mamba-transformer backbone으로, pure replacement보다 결합형 설계가 현실적일 수 있음을 보여 준다.[11]

이건 중요한 신호다.

- 신흥 백본이 기존 계보를 단숨에 대체하기보다 hybrid로 스며드는 경우가 많다
- 연구 질문은 “누가 최종 승자인가”보다 “어떤 mixing mechanism을 어디에 둘 것인가”가 더 생산적이다

8. 태스크별로 어떤 백본이 유리한가

8-1. classification 중심

대규모 pretraining 환경에서는 ViT류가 여전히 매우 강하다.[5]
하지만 strong ConvNet도 충분히 경쟁력 있고, 특히 moderate-scale setting에서는 ConvNeXt류가 여전히 강한 기준선이다.[3][4]

8-2. detection / segmentation 중심

계층형 구조와 multi-scale 표현이 중요하므로 Swin, ConvNeXt, InternImage처럼 dense task 친화성이 높은 백본이 더 실용적이다.[3][7][8]

8-3. mobile / edge 중심

여전히 MobileNet류와 EfficientNet류 사고방식이 중요하다.[1][2]
이 환경에서는 operator availability와 memory access pattern이 accuracy 몇 점보다 더 중요할 수 있다.

8-4. small-data / domain-specific 중심

강한 구조적 bias가 있는 CNN/ConvNet류가 더 안정적인 출발점이 되는 경우가 많다.
Transformer류는 pretraining 혜택이 크지만, fine-tuning sensitivity와 data requirement를 함께 봐야 한다.[3][5][6]

8-5. long-range video / high-resolution 중심

SSM/Mamba 계열과 hierarchical transformer 계열 모두 연구 가치가 있다.
다만 2026년 현재는 “이론적으로 유망”과 “실전적으로 검증 완료”를 구분해서 봐야 한다.[9][10][11]

9. 실제로 백본을 고를 때 쓸 수 있는 의사결정 프레임

실험을 시작하기 전 아래 질문을 먼저 던지면 좋다.

1. 내 태스크는 classification 중심인가, dense prediction 중심인가
2. 데이터는 큰가, 작은가
3. inference target은 서버인가, edge인가
4. pretraining을 쓸 수 있는가
5. 고해상도 입력이 핵심인가
6. 학습 속도와 재현성이 얼마나 중요한가

이 질문에 대한 대략적 선택 가이드는 아래와 같다.

- `강한 기준선 + 안정성`이 필요하면 ConvNeXt
- `대규모 pretraining ceiling`을 보고 싶으면 ViT/DeiT 계열
- `dense task와 multi-scale 친화성`이 중요하면 Swin
- `비전 특화 적응형 spatial modeling`을 보고 싶으면 InternImage
- `새 mixing mechanism 실험`이 목적이면 VMamba / MambaVision
- `모바일 배포`가 핵심이면 MobileNetV2 / EfficientNet 계보를 시작점으로

10. 지금 시점에서 연구적으로 가장 중요한 질문

10-1. backbone quality는 representation 문제인가, training culture 문제인가

ConvNeXt와 DeiT가 보여 준 가장 중요한 사실 중 하나는, architecture 우열의 일부가 recipe와 pretraining setup에 묻혀 있다는 점이다.[3][4][6]

10-2. dense prediction에서 multi-scale은 본질인가

Swin과 InternImage, 그리고 detection/segmentation 계보를 보면 multi-scale hierarchy는 단순 전통이 아니라 문제 구조일 가능성이 크다.[7][8]

10-3. long-range modeling은 attention만의 영역인가

SSM 계열은 여기에 새로운 반론을 제시한다.[9][10][11]

10-4. 실제 효율은 왜 이론 효율과 다르게 보이는가

모바일과 edge에서는 operator maturity, memory traffic, framework support가 큰 차이를 만든다.[1][2]

11. 내가 바로 해볼 만한 비교 실험

실험 A: modern ConvNet vs hierarchical transformer

- backbone: ConvNeXt-T vs Swin-T
- task: COCO detection 또는 ADE20K segmentation
- 측정: AP/mIoU, latency, GPU memory, convergence speed

실험 B: large-scale pretraining benefit

- backbone: ConvNeXt V2 vs ViT/DeiT
- 설정: supervised pretraining vs self-supervised pretraining
- 질문: backbone 차이보다 pretraining 차이가 더 큰가

실험 C: domain-specific small-data transfer

- backbone: ConvNeXt, Swin, InternImage
- 데이터: 의료/산업/원격탐사 중 하나
- 질문: 적은 데이터와 shift 환경에서 어떤 구조가 가장 안정적인가

실험 D: new mixer evaluation

- backbone: Swin vs VMamba vs MambaVision
- 입력: 고해상도 또는 긴 시퀀스
- 질문: 이론 scaling 이점이 실제 wall-clock과 downstream metric으로 이어지는가

12. 읽기 우선순위

이 주제를 빠르게 잡으려면 아래 순서가 좋다.

1. MobileNetV2, EfficientNet
   효율 백본의 기본 문법

2. ViT, DeiT
   Transformer 백본이 왜 강해졌는지

3. Swin
   dense task 친화적 transformer의 핵심

4. ConvNeXt, ConvNeXt V2
   현대적 ConvNet의 재정립

5. InternImage
   대규모 비전 특화 convolution

6. Vision Mamba, VMamba, MambaVision
   차세대 mixer 탐색

최종 정리

2026년의 비전 백본 연구는 `CNN vs Transformer` 같은 이분법으로 보면 거의 반드시 놓친다.

더 정확한 프레임은 아래다.

- 어떤 태스크인가
- 어떤 데이터 regime인가
- 어떤 pretraining을 쓸 것인가
- 어떤 해상도와 latency 제약이 있는가
- 어떤 spatial prior와 global mixing이 필요한가

즉 좋은 백본은 절대적 승자가 아니라 `문제 구조와 시스템 제약에 가장 잘 맞는 표현 추출기`다.

참고문헌

[1] Sandler et al., *MobileNetV2: Inverted Residuals and Linear Bottlenecks* (CVPR 2018)
CVF Open Access

[2] Tan and Le, *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks* (ICML 2019)
PMLR

[3] Liu et al., *A ConvNet for the 2020s* (CVPR 2022)
CVF Open Access

[4] Woo et al., *ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders* (CVPR 2023)
CVF Open Access

[5] Dosovitskiy et al., *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale* (ICLR 2021)
OpenReview

[6] Touvron et al., *Training data-efficient image transformers & distillation through attention* (ICML 2021)
PMLR

[7] Liu et al., *Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows* (ICCV 2021)
CVF Open Access

[8] Wang et al., *InternImage: Exploring Large-Scale Vision Foundation Models with Deformable Convolutions* (CVPR 2023)
CVF Open Access

[9] Zhu et al., *Vision Mamba: Efficient Visual Representation Learning with Bidirectional State Space Model* (ICML 2024)
PMLR

[10] Liu et al., *VMamba: Visual State Space Model* (NeurIPS 2024)
OpenReview

[11] Hatamizadeh et al., *MambaVision: A Hybrid Mamba-Transformer Vision Backbone* (CVPR 2025)
CVF Open Access