2026 해무 시정 분류 논문 주제 후보 4선

기준일: 2026-04-22

목적

이 문서는 현재 보유한 항만 해무 이미지 데이터를 기준으로, 실제로 논문으로 밀 수 있는 강한 주제 후보 4개를 정리한 실전용 노트다.

현재 전제는 아래와 같다.

- 데이터는 보통시정 - 저시정 - 해무의 3단 분류 라벨을 가진 이미지 데이터셋이다
- 전국 11개 항 데이터가 있으나, 실제로 논문에 쓸 만한 품질/양/일관성을 가진 항은 약 4개 항 정도다
- 문제 배경은 항만 모니터링, 해상 안전, 시정 기반 운영 판단 같은 safety-relevant vision task다
- 연구자는 CNN 기반 컴퓨터비전 / 영상처리 엔지니어 관점에서 주제를 잡고 싶다
- 사용 가능한 연산 자원은 H200 GPU 2장이다

핵심 메시지는 간단하다.

- 이 데이터의 진짜 가치는 단순 3분류가 아니다
- 항만 간 분포 차이, 현실 배포형 일반화, 안전-critical 오분류 비용, 경량 배포 가능성이 핵심이다
- 따라서 논문도 정확도 몇 % 향상보다 cross-site robustness, uncertainty, data-centric protocol, deployment-aware design 쪽이 훨씬 강하다

빠른 결론

지금 당장 가장 강한 후보는 아래 순서다.

1. Cross-Port Generalization Benchmark for Harbor Fog Visibility Classification
2. Uncertainty-Aware Fog Visibility Classification under Harbor Site Shift
3. Data-Centric Site-Generalized Fog Classification with Limited Multi-Port Data
4. Lightweight and Selective CNN for Real-Time Harbor Fog Monitoring

이 중에서 첫 논문 1편을 고르라면 후보 1이 가장 안정적이다.
데이터셋의 가치가 가장 잘 드러나고, 후속 논문으로 후보 2~4를 자연스럽게 이어 붙일 수 있기 때문이다.

---

1. 공통 데이터 프레임

네 후보 모두 아래 데이터 프로토콜 위에서 설계하는 것이 좋다.

데이터 전제

- 사용 항만: 품질이 안정적인 4개 항
- 클래스: 보통시정 / 저시정 / 해무
- 입력: 고정 CCTV 또는 준고정 시점 이미지
- 추가 메타정보가 있으면 적극 활용
  - 항만 ID
  - 촬영 시각

    - 계절/월
    - 주야간
    - 기상/시정 계측값

권장 평가 split

1. `Within-port split`

- 각 항만 내부 train/val/test 분할
- 순수 분류 난이도 확인용

2. `Leave-one-port-out`

- 4개 항 중 1개 항을 통째로 test로 두는 4-fold
- 가장 중요한 핵심 평가

3. `Temporal split`

- 가능하면 시간 기준으로 train/test 분리
- 같은 날/같은 시간대 leakage 방지

4. `Day/Night or Season split`

- 메타정보가 있으면 추가
- 실제 배포 robustness 분석에 중요

공통 핵심 metric

- `Macro-F1`
- `Balanced Accuracy`
- `Per-class Recall`
- `Fog Recall`
- `Low-Visibility Recall`
- `ECE`
- `Brier Score`
- `AUROC for reject option`

실전 맥락에서는 `해무 미탐`과 `저시정 미탐` 비용이 크므로, top-1 accuracy보다 아래를 더 강조하는 편이 좋다.

- 해무 recall
- 위험 클래스 묶음 recall: `저시정 + 해무`
- calibrated confidence
- abstention 성능

---

2. 후보 1: Cross-Port Generalization Benchmark for Harbor Fog Visibility Classification

한 줄 정의

`4개 항만 실환경 이미지에서, 같은 항 안에서는 잘 맞는 모델이 다른 항으로 가면 얼마나 무너지는지 체계적으로 보여 주는 benchmark/protocol 논문`

왜 강한가

이 후보는 데이터의 본질적 가치를 가장 잘 살린다.

- 단순 3클래스 분류보다 `site shift` 문제가 논문적으로 훨씬 크다
- "모델 하나 제안"보다 "현실적인 문제 정의 + 프로토콜 제안"이 더 오래 간다
- 후속 연구의 기준선 문서가 될 수 있다

특히 4개 항뿐이어도 아래가 성립하면 충분히 논문감이 있다.

- 항만별 배경과 시야가 다르다
- 조명과 날씨 패턴이 다르다
- 클래스 분포가 다르다
- within-port와 cross-port 성능 차이가 분명하다

핵심 연구 질문

- 항만 내부 IID 평가에서는 강한 CNN이, unseen 항만에서는 얼마나 성능이 무너지는가
- backbone 차이보다 `site shift`가 더 큰 요인인가
- 어떤 학습 설정이 cross-port generalization에 상대적으로 유리한가

주장 구조

1. `항만 내부 성능과 항만 간 일반화 성능은 다르다`
2. `같은 accuracy라도 항만 이동 시 calibration과 fog recall은 더 크게 붕괴한다`
3. `CNN 계열 baseline 사이에도 generalization gap 차이가 존재한다`

최소 실험 세트

- backbone:
  - ResNet-50
  - EfficientNet-B2 또는 B3
  - ConvNeXt-T
  - MobileNetV3-Large
- 선택적 비교:
  - Swin-T 1개 정도만 추가
- protocol:
  - within-port
  - leave-one-port-out 4-fold
  - 시간 분리 평가 가능 시 추가
- 분석:
  - confusion matrix by port

    - port-wise calibration
    - class prior shift 분석
    - 해무/저시정 failure case 시각화

H200 2장 기준 실험 설계

이 주제는 거대 모델이 필요 없다.
H200 2장의 강점은 `매우 많은 split과 반복실험을 빠르게 소화할 수 있다`는 점이다.

권장 방식:

1. 1차 스크리닝

- 해상도 224
- 4개 backbone
- 4-fold leave-one-port-out
- seed 2개

2. 2차 본실험

- 상위 2~3개 backbone만 남김
- 해상도 224 / 384 비교
- augmentation on/off
- seed 3개

3. 추가 분석

- temperature scaling
- reliability diagram
- per-port embedding visualization

즉 이 주제는 H200을 `대형 foundation model`에 쓰는 게 아니라 `반복 가능한 강한 실험 프로토콜`에 쓰는 게 맞다.

예상 장점

- 가장 논문 구조가 안정적이다
- 데이터셋 소개와 baseline만으로도 문서 골격이 선다
- 후속으로 uncertainty, DG, on-device 논문이 자연스럽게 이어진다

예상 약점

- “새 모델이 없다”는 약점이 생길 수 있다
- 따라서 분석 깊이가 중요하다

보완 포인트:

- 단순 benchmark가 아니라 `site shift taxonomy`
- port-specific failure analysis
- calibration과 selective prediction까지 포함

추천도

최우선

---

3. 후보 2: Uncertainty-Aware Fog Visibility Classification under Harbor Site Shift

한 줄 정의

항만 시정 분류에서 정확도보다 더 중요한 것은 “모델이 모르는 상황을 얼마나 잘 감지하는가”라는 문제를 다루는 논문

왜 강한가

항만 해무 분류는 실무적으로 safety-critical하다.

- 해무를 보통시정으로 잘못 분류하면 운영상 위험
- unseen 항만이나 이상 조명에서 confidence가 과도하면 더 위험

즉 이 주제는 단순 인식 문제가 아니라 `risk-aware vision`으로 포지셔닝할 수 있다.

핵심 연구 질문

- cross-port shift에서 정확도보다 calibration이 더 크게 무너지는가
- uncertainty-aware method가 실제로 fog miss를 줄이는가
- selective prediction이 항만 모니터링에서 유효한 운영 전략이 되는가

주장 구조

1. `cross-port 환경에서 softmax confidence는 신뢰하기 어렵다`
2. `temperature scaling, deep ensemble, MC dropout, focal loss 계열은 효과가 다르다`
3. `selective prediction 또는 abstention을 넣으면 안전성 지표가 유의미하게 개선된다`

최소 실험 세트

- backbone:
  - ConvNeXt-T
  - EfficientNet-B3
  - MobileNetV3-Large
- uncertainty method:
  - baseline softmax
  - temperature scaling
  - focal loss
  - deep ensemble
  - MC dropout
- metric:
  - ECE
  - NLL

    - Brier Score
    - risk-coverage curve
    - fog recall at fixed coverage

H200 2장 기준 실험 설계

이 후보는 ensemble 때문에 연산량이 늘지만, H200 2장이면 충분히 강한 실험이 가능하다.

권장 방식:

1. backbone 2개만 선정

- ConvNeXt-T
- EfficientNet-B3

2. leave-one-port-out 4-fold 수행

3. 각 fold마다

- baseline 1개
- temperature scaling 1개
- MC dropout 1개
- ensemble 3~5개 모델

4. 최종 비교

- 정확도 기준 순위
- calibration 기준 순위
- fog miss rate 기준 순위

실제로는 이 주제에서 H200 2장의 진짜 가치는 `앙상블과 다중 fold를 동시에 현실적으로 돌릴 수 있다`는 점이다.

이 주제가 더 강해지는 조건

아래 중 하나라도 있으면 강해진다.

- 현장 운영에서 false negative 비용 설명 가능
- confidence threshold 기반 알림 정책 설계 가능
- 불확실 예측을 “재검토 필요”로 넘기는 운영 시나리오 제시 가능

예상 장점

- 실무성과 논문성이 동시에 있다
- 단순 accuracy paper보다 훨씬 설득력이 높다
- 후속으로 active learning, human-in-the-loop로 확장 가능하다

예상 약점

- 데이터가 너무 쉬우면 uncertainty 차이가 약하게 보일 수 있다
- 따라서 `cross-port test`, `야간/계절 split`, `hard subset`이 중요하다

추천도

매우 높음

---

4. 후보 3: Data-Centric Site-Generalized Fog Classification with Limited Multi-Port Data

한 줄 정의

모델을 크게 바꾸지 않고도, 데이터 샘플링·정제·균형화·증강만으로 cross-port 성능을 얼마나 끌어올릴 수 있는지 보여 주는 논문

왜 강한가

네 배경과 가장 잘 맞는 주제 중 하나다.

- CNN 엔지니어링 강점과 잘 맞는다
- 데이터셋이 작거나 불균형할수록 data-centric 접근이 잘 먹힌다
- 실무적으로 바로 쓸 수 있는 결과가 나온다

핵심 연구 질문

- 항만별 데이터 불균형과 클래스 편향이 cross-port 성능 저하의 주요 원인인가
- hard case mining, class-balanced sampling, domain-balanced batching이 실제로 유효한가
- style augmentation 또는 weather augmentation이 항만 간 일반화에 도움이 되는가

주장 구조

1. 성능 병목의 상당 부분은 backbone보다 데이터 분포 불균형에서 온다
2. class-balanced sampling + port-balanced batching + hard example mining 조합이 baseline보다 안정적이다
3. 증강은 clean accuracy보다 cross-port robustness에서 더 큰 이득을 준다

최소 실험 세트

- backbone 고정:
  - ResNet-50 또는 ConvNeXt-T 하나 고정
- data-centric intervention:
  - vanilla sampling
  - class-balanced sampling
  - port-balanced batching
  - focal loss / class-balanced loss
  - hard example mining
  - weather/style augmentation
- metric:
  - cross-port Macro-F1
  - fog recall

    - worst-port accuracy
    - calibration shift

H200 2장 기준 실험 설계

이 주제는 실험 수가 많아진다.
대신 backbone을 거의 고정해 두면 H200 2장으로 매우 풍부한 ablation을 할 수 있다.

권장 방식:

1. backbone 1개 고정

- ConvNeXt-T 또는 ResNet-50

2. ablation grid 실행

- sampling 3종
- loss 2종
- augmentation 3종
- fold 4개

3. 상위 조합만 seed 3개 반복

이렇게 하면 “아키텍처가 아니라 데이터 설계가 cross-site 성능을 바꾼다”는 메시지를 강하게 밀 수 있다.

예상 장점

- 논문 메시지가 실전적이다
- 구현 난도가 비교적 낮다
- 결과가 잘 나오면 산업 적용 설득력이 매우 높다

예상 약점

- 아이디어가 너무 공학적으로 보일 수 있다
- 따라서 분석을 꼭 넣어야 한다

필수 분석:

- 항만별 데이터 구성표
- intervention 전후 confusion shift
- hardest subset에서의 개선량
- 어떤 오류가 줄었는지 qualitative case study

추천도

높음

---

5. 후보 4: Lightweight and Selective CNN for Real-Time Harbor Fog Monitoring

한 줄 정의

항만 현장 배포를 염두에 두고, 경량 CNN이 어느 수준까지 정확도와 안전성을 동시에 확보할 수 있는지 보여주는 deployment-aware 논문

왜 강한가

이 주제는 연구 깊이만 보면 후보 1~3보다 약간 덜 강할 수 있다.
하지만 실제 제품화와 현장 적용 관점에서는 매우 설득력이 있다.

특히 아래 두 요소를 합치면 좋아진다.

- lightweight backbone
- selective prediction 또는 early-exit

즉 항상 답을 하는 모델이 아니라 빠르게 판단하되 애매하면 보수적으로 넘기는 모델을 만드는 방향이다.

핵심 연구 질문

- MobileNet/EfficientNet/소형 ConvNeXt가 항만 시정 분류에서 어느 정도까지 충분한가
- 경량 모델에서 calibration과 selective prediction을 붙이면 대형 모델의 일부 안전성을 회수할 수 있는가
- 실제 운영 지표 기준 최적점은 어디인가

주장 구조

1. 항만 시정 모니터링은 대형 모델이 아니라 충분히 좋은 경량 모델로도 운영 가능하다
2. 단순 정확도 최적화보다 latency-aware selective design이 운영 위험을 줄인다
3. 경량화 후에도 fog recall과 abstention 전략을 적절히 설계하면 실전성이 높다

최소 실험 세트

- backbone:
  - MobileNetV3-Large
  - EfficientNet-B0/B2
  - ConvNeXt-Tiny 또는 Nano 계열
- deployment setting:
  - FP32 baseline
  - mixed precision
  - INT8 PTQ 또는 QAT 가능 시 추가
- metric:
  - latency
  - throughput
  - model size
  - power proxy가 있으면 추가
  - fog recall at fixed latency budget

H200 2장 기준 실험 설계

학습 자체는 H200 2장에 비해 가볍다.
따라서 이 주제에서는 훈련보다 반복 측정과 최적화 탐색에 자원을 쓰는 게 맞다.

권장 방식:

1. 작은 backbone 여러 개를 동시에 스크리닝
2. 상위 2개 모델에 대해

- 해상도별 비교
- quantization 전후 비교
- selective threshold sweep

3. 최종적으로

- latency-accuracy
- latency-fog recall
- coverage-risk curve

예상 장점

- 현장 적용 설득력이 강하다
- 산업체/운영기관 설득에 좋다
- 후속 PoC로 이어지기 쉽다

예상 약점

- 순수 학술 novelty는 상대적으로 약하다
- 그래서 selective prediction, calibration, cross-port test를 꼭 결합해야 한다

추천도

중상

---

6. 네 후보의 우선순위 비교

후보 1이 가장 좋은 이유

- 데이터의 본질적 가치를 가장 정직하게 보여 준다
- 과장 없이도 메시지가 선다
- 후속 논문 파생력이 가장 높다

후보 2가 두 번째로 강한 이유

- safety-critical framing이 분명하다
- 단순 정확도 논문보다 훨씬 강하다
- 운영 관점 설득력이 있다

후보 3이 실전적으로 좋은 이유

- 구현 난도 대비 결과가 잘 나올 가능성이 높다
- 엔지니어링 성과를 논문 메시지로 바꾸기 쉽다

후보 4가 유용한 이유

- 제품화/배포형 논문으로 좋다
- 다만 첫 대표 논문으로는 1~3보다 약간 뒤다

7. 첫 논문으로 무엇을 고를까

가장 추천하는 1편은 아래다.

`Cross-Port Generalization for Fog Visibility Classification in Real-World Harbor Camera Images`

이 주제의 장점은 아래다.

- 데이터셋 가치를 가장 잘 드러낸다
- baseline만으로도 논문 골격이 선다
- 이후 2편째 논문으로 uncertainty-aware 후속을 붙이기 좋다

가장 추천하는 2편 연속 시나리오는 아래다.

1. 첫 논문: `후보 1`
2. 후속 논문: `후보 2`

이렇게 가면

- 1편에서 문제와 benchmark를 정의하고
- 2편에서 안전성과 uncertainty를 파고
- 3편에서 data-centric 개선이나 deployment형 확장을 붙일 수 있다

---

8. H200 2장 기준 전체 연구 운영 전략

네 환경에서는 `대형 모델 한두 개를 무겁게 돌리는 전략`보다 아래가 더 효율적이다.

단계 1. 데이터 진단

- 4개 항만의 샘플 수 정리
- 클래스 분포 정리
- 시간대/계절 분포 정리
- 유사 이미지/연속 프레임 leakage 점검

단계 2. 강한 baseline 확정

- ResNet-50
- EfficientNet-B3
- ConvNeXt-T
- MobileNetV3-Large

여기서 1차 랭킹을 만든다.

단계 3. leave-one-port-out 프로토콜 고정

- 이후 모든 실험은 이 프로토콜 위에서 진행
- within-port 성능은 보조 지표로만 사용

단계 4. 본주제 1개를 선택해 깊게 판다

- 후보 1이면 분석 깊이
- 후보 2면 uncertainty와 abstention
- 후보 3이면 data ablation
- 후보 4면 deployment sweep

단계 5. 반복 실험에 자원을 집중한다

H200 2장은 "모델을 비정상적으로 크게" 만드는 데 쓰기보다 아래에 쓰는 편이 낫다.

- fold 반복
- seed 반복
- calibration 반복
- ablation 반복
- error analysis

즉 이 연구에서는 `연산 자원의 질`보다 `실험 설계의 밀도`가 논문 품질을 결정한다.

최종 정리

이 데이터로 가장 약한 논문은 `3분류 정확도 개선`이고, 가장 강한 논문은 `현실적인 항만 간 일반화 문제를 정의하고, 그 위에서 안전성과 배포성을 다루는 논문`이다.

따라서 추천 순서는 아래다.

1. `Cross-Port Generalization Benchmark`
2. `Uncertainty-Aware Safety-Critical Classification`
3. `Data-Centric Site Generalization`
4. `Lightweight Selective Deployment`

첫 논문은 `후보 1`, 두 번째 논문은 `후보 2`로 가는 흐름이 가장 안정적이다.